



universität
wien

BACHELORARBEIT

Titel der Bachelorarbeit

Eine Exponentielle Obere Schranke für Wahrscheinlichkeiten Atypischer
Mengen Diskreter Erinnerungsloser Quellen

Verfasser

Alexander Jerschow

angestrebter akademischer Grad
Bachelor of Science (BSc)

Wien, 02-2024

Studienkennzahl lt. Studienblatt:
Studienrichtung lt. Studienblatt:
Betreuer:

1204 9824
Mathematik
Pf. Mathias Beiglböck

Abriss

Diese Arbeit dient als Einführung in die Konzepte von Entropie und Typen als Motivation für die Sanov'sche Ungleichheit: eine obere Schranke von Wahrscheinlichkeiten atypischer Mengen, die exponentiell abfällt. Wir ziehen einen Vergleich mit bekannteren Schranken wie jener, welche mit der Chebyshev'schen Ungleichung hergeleitet wird, die, im Gegensatz, sublinear konvergiert. Nach der Einführung von Typen und Typklassen, in der wir ein Paar nützliche Schranken und Gleichheiten ihrer Wahrscheinlichkeiten und Mächtigkeiten beweisen, interpretieren wir die Entropie als Unsicherheitsmaß und verbinden diese Interpretation mit der asymptotischen Equipartitionseigenschaft. Dann beweisen und interpretieren wir unsere vorher erwähnte obere Schranke (die Sanov'sche Ungleichheit), sowie eine analoge untere falls zusätzliche Voraussetzungen zutreffen. Infolgedessen ergibt sich ein Limes, welcher hauptsächlich von theoretischem Interesse ist (der Sanov'sche Satz über große Abweichungen). Zum Abschluss werden ein Paar Anwendungsbeispiele dieser Ungleichheit in der rares Ereignisanalyse besprochen werden.

Inhaltsverzeichnis

1	Einführung	3
2	Entropie	3
3	Typen und Typklassen	4
4	Kullback-Leibler Divergenz	4
5	Hauptresultate Betreffs Typizität	5
6	Entropie als Unsicherheit	8
7	Die Asymptotische Equipartitionseigenschaft	10
8	Ungleichung und Satz der großen Abweichungen von Sanov	11
9	Anwendungen der Sanov'schen Ungleichung	12

1 Einführung

In vielen Situationen in der statistischen und probabilistischen Modellierung möchte man die Wahrscheinlichkeit irgendeines Ereignisses oder Fehlers minimieren. Bspw. ist es oftmals der Fall, dass man einen Schätzer, wie z. B. den empirischen Durchschnitt, n unabhängiger und identisch verteilter (u.i.v.) Zufallsvariablen betrachtet. Durch ein theoretisches Resultat wie das Gesetz der großen Zahlen oder sonstiges ist die Konvergenz des Schätzers gegen einen erwünschten Wert üblicherweise gegeben. Abgesehen von dieser Konvergenz, möchte man auch wissen wie viele Versuche man bräuchte, um eine gewisse Zuversicht zu gewährleisten, dass man innerhalb eines ϵ dieses erwünschten Wertes ist. Die oben erwähnten Ziele sind einige der grundlegendsten der Theorie über große Abweichungen und Rares Ereignisanalyse.

Im Falle des empirischen Durchschnittes, eine Möglichkeit, um eine obere Schranke von der Wahrscheinlichkeit, dass man weg von dem wahren Erwartungswert ist, zu setzen, könnte durch die Chebyshev'sche Ungleichung gefunden werden:

$$P(|\bar{X}_n - \mu| \geq \epsilon) \leq \frac{\text{Var}[\bar{X}_n]}{\epsilon^2},$$

wo $\mu := E[X_1]$. Wir könnten jetzt die Additivität von Varianzen unabhängiger Zufallsvariablen, die Eigenschaft, dass die Varianz mit Grad zwei homogen ist und, dass unsere Zufallsvariablen identisch verteilt sind zunutze machen um Folgendes zu erzielen:

$$P(|\bar{X}_n - \mu| \geq \epsilon) \leq \frac{\text{Var}[X_1]}{n\epsilon^2}.$$

Abgesehen von der Forderung der Existenz des zweiten Moments unserer Verteilung, wir sehen auch, dass dieser Fehler in n gegen die Null sublinear konvergiert. In Situationen wo die Durchführung von Versuchen, um einen Schätzer zu verbessern, teuer ist (bzgl. Zeit, Geld oder einer anderen Ressource), ist eine niedrigere Schranke offensichtlich vorzuziehen, denn sie ergibt eine Ressource-effizientere Lösung unseres Problems. Unser Ziel wird es sein, eine obere Schranke von solchen Wahrscheinlichkeiten zu finden, welche exponentiell abfällt.

2 Entropie

Unser Rahmen wird jenem der Einführung ähneln. Genauer gesagt: eine diskrete erinnerungslose Quelle (DEQ) ist eine Folge $(X_1, X_2, \dots)$ unabhängiger und identisch verteilter (u.i.v.) Zufallsvariablen, die Werte in einer endlichen Menge E annimmt, welche als Quellenalphabet bezeichnet wird. Die zugrundeliegende Verteilung jedes X_i heißt generische Verteilung [5]. Darüber hinaus, eines der grundlegenden Konzepte, das wir brauchen werden, ist die Entropie einer Zufallsvariable:

$$H(X) := - \sum_{x \in E} p(x) \log p(x), \quad (2.1)$$

$$H(X) := - \int_E p(x) \log p(x) dx = - \int_{\Omega} \log p(X) dP = E[-\log(p(X))], \quad (2.2)$$

wo Ω unser Grundraum, P das entsprechende Wahrscheinlichkeitsmaß auf Ω , und p die Wahrscheinlichkeitsmassenfunktion oder Dichte der Zufallsvariable X ist. Wir übernehmen die Konvention: $0 \cdot \log 0 = 0$. Man beachte, (2.1) bezieht sich lediglich auf diskrete X und das erste Integral von (2.2) auf stetige X . Wir dürfen zusätzlich $H(Q)$, wo Q die Verteilung von X ist, schreiben. Es soll erwähnt werden, dass, je nach Zusammenhang, die Base des Logarithmus üblicherweise e oder 2 ist. In dieser Arbeit wird durchgehend 2 verwendet, sofern nicht explizit anders angegeben. Gleichwohl bemerkt man, die meisten Konsequenzen bleiben für beliebige Basen wahr.

Die Entropie ist eine Art Maß für Unsicherheit, Information, oder „Überraschung“. Die Idee hinter der Definition ist, dass weniger wahrscheinliche Ereignisse mehr „Überraschung“ ergeben sollten falls sie geschehen, weswegen eine Abbildung wie $-\log$ mit einem Pol bei Null eine natürliche Wahl sein könnte. Denn dann hätten wir eine Abbildung, welche einem Ereignis x mit kleiner Wahrscheinlichkeit $p(x)$

einen großen „Überraschungsbetrag“ zuordnet. Indem wir dann die gewichtete Summe/das gewichtete Integral dieser Logarithmen nehmen (mit Gewichten gemäß p), erhält man im Grunde die Erwartung, oder durchschnittliche Überraschung des Ereignisses einer Zufallsvariable. Es gibt eine andere Motivation für die Entropie, welche mit dem Multinomialkoeffizienten verknüpft ist, was die Anzahl der Permutationen n Elemente ist, wo wir Unterschiede zwischen n_1 Elementen, n_2 anderen Elementen, $n_3 \dots$ vernachlässigen. Dieser ist gegeben durch:

$$\binom{n}{n_1, \dots, n_k} = \frac{n!}{n_1! \cdots n_k!}.$$

Man überprüft leicht, dass dieser Ausdruck tatsächlich jene Zahl ist, die wir suchen, indem man beobachtet, dass jede Permutation, die zwischen n_1 Elementen nicht unterscheidet, $n_1!$ weitere ergibt, die das machen. Daher haben wir $\frac{n!}{n_1!}$ mögliche Permutationen im Falle $i = 1$ (setze induktiv fort). Es sollte angemerkt werden, dieser Koeffizient ergibt lediglich dann Sinn, falls $n = \sum_{i=1}^k n_i$. Wir werden sehen wie, genau, diese Zahl mit der Entropie verbunden ist, nachdem wir zunächst ein Paar Resultate über Typen besprechen:

3 Typen und Typklassen

Der Typ P_x einer gemäß unserer DEQ produzierten Folge $x \in E^n$ ist ihr Histogramm:

$$P_x(a) := \frac{N(a|x)}{n},$$

wobei $N(a|x) := |\{i \in [1, n]_{\mathbb{N}} | x_i = a\}|$ die Anzahl an Vorkommnissen des Elements $a \in E$ in unserer gegebenen Folge x bezeichnet. Zusätzlich ist die Typklasse $T(P)$ einer gegebenen Verteilung $P \in \mathcal{P}_n$ die Menge der Folgen mit Typ P :

$$T(P) := \{x \in E^n | P_x = P\},$$

wo $\mathcal{P}_n$ die Verteilungen mit Nenner n beschreibt, i.a.W. die Menge der Verteilungen P , so dass $\text{Im}(nP) \in \mathbb{N}$. Schauen wir uns ein kurzes Beispiel an, welches diese Begriffe näherbringt [2]:

$E := \{1, 2, 3\}, x := (1, 1, 1, 3, 2) \in E^5$, dann:

$P_x(1) = 3/5, P_x(2) = P_x(3) = 1/5$, und:

$T(P_x) = \{x \in E^5 | N(3|x) = N(2|x) = 1, N(1|x) = 3\}$, die Menge aller $x \in E^5$, so dass 1 drei

Male, und 2 und 3 ein Mal vorkommen.

P_x kann als die beste Vermutung für die zugrundeliegende Verteilung, welche zu x geführt hat, und $T(P)$ als die Menge aller Folgen, welche zu einer besten Vermutung P führen würde, aufgefasst werden. Man bemerkt auch, dass die Typklassen eine Partition des Raums E^n bilden. Denn jede Folge $x \in E^n$ hat einen durch die Definition bestimmten Typ, ist daher in einer Typklasse. Überdies kann x in keiner anderen Typklasse liegen, denn dann hätte x zwei Typen und wäre keine Permutation von sich selbst (aus der Definition ist ersichtlich, dass alle Permutationen einer Folge zum selben Typ führen, da $N(a|x)$ permutationsinvariant ist), was natürlich unwahr ist. Wir werden sehen, dass die Menge der Folgen, welche „nah“ zur generischen Verteilung sind, ist wo fast die ganze Masse unseres (Produkt)Wahrscheinlichkeitsmaßes liegt wenn $n \rightarrow \infty$. Aber zunächst müssen wir verdeutlichen, was wir meinen, wenn wir sagen, dass eine Verteilung „nah“ zu einer anderen ist:

4 Kullback-Leibler Divergenz

Es wird sich herausstellen, dass die Kullback-Leibler Divergenz (auch relative Entropie oder Informationsdivergenz) als Ähnlichkeitsmaß zweier Verteilungen unseren Bedürfnissen entspricht:

$$D(P||Q) := \begin{cases} \sum_{x \in \Omega} P(x) \log \frac{P(x)}{Q(x)} & P \ll Q \\ \infty & \text{ansonsten} \end{cases} \quad (4.1)$$

$$D(P||Q) := \begin{cases} \int_{\Omega} p(x) \log \frac{p(x)}{q(x)} dx = \int_{\Omega} \log \left(\frac{dP}{dQ} \right) dP & P \ll Q \\ \infty & \text{ansonsten} \end{cases} \quad (4.2)$$

wo (4.1) für diskrete Verteilungen gedacht ist, (4.2) für stetige, p und q entsprechende Dichtenfunktionen, $\frac{dP}{dQ}$ die Radon-Nikodym Ableitung von P nach Q , und Ω der Grundraum sind. Wir entsinnen uns auch dessen, dass ein Maß P bzgl. Q genau dann absolut stetig ist ($P \ll Q$), wenn alle Nullmengen von Q gleichfalls von P sind. Zuletzt, falls $X \sim p$ und $Y \sim q$ Zufallsvariablen mit Werten in E sind, dann:

$$E \left[\log \frac{p(X)}{q(Y)} \right] = D(p||q),$$

wo p und q Wahrscheinlichkeitsmassenfunktionen oder Dichten von X und Y sind, je nachdem, ob X und Y stetig sind. Es ist wichtig, sich bewusst zu machen, dass wenngleich die Kullback-Leibler Divergenz oft als Unterscheidungsmaß zwischen zwei Verteilungen betrachtet wird, sie ist keine Metrik, denn sie erfüllt weder Symmetrie noch die Dreiecksungleichung:

$$\begin{aligned} D \left(\text{Ber} \left(\frac{1}{2} \right) \parallel \text{Ber} \left(\frac{3}{4} \right) \right) &\approx 0.21 \neq 0.19 \approx D \left(\text{Ber} \left(\frac{3}{4} \right) \parallel \text{Ber} \left(\frac{1}{2} \right) \right). \\ D \left(\text{Ber} \left(\frac{1}{4} \right) \parallel \text{Ber} \left(\frac{3}{4} \right) \right) &\approx 0.79 \not\leq 0.4 = 0.19 + 0.21 \approx \\ D \left(\text{Ber} \left(\frac{1}{4} \right) \parallel \text{Ber} \left(\frac{1}{2} \right) \right) &+ D \left(\text{Ber} \left(\frac{1}{2} \right) \parallel \text{Ber} \left(\frac{3}{4} \right) \right). \end{aligned}$$

Die KL Divergenz erfüllt jedoch positiv-Definitheit, denn falls $X \sim p$ und $Y \sim q$ Zufallsvariablen sind, welche Werte in E nehmen:

$$\begin{aligned} D(p||q) &= E \left[\log \frac{p(X)}{q(X)} \right] = E \left[-\log \frac{q(X)}{p(X)} \right] > -\log \left(E \left[\frac{q(X)}{p(X)} \right] \right) = -\log \left(\int_E p(x) \frac{q(x)}{p(x)} dx \right) \\ &= -\log \left(\int_E q(x) dx \right) = -\log(1) = 0 \end{aligned}$$

nach der Jensen'schen Ungleichung, da $-\log$ streng konvex ist. Falls es sich um eine Gleichheit handelt, wissen wir, dass $\frac{p(X)}{q(X)}$ konstant ist. Da diese Konstante unter der Abbildung $-\log$ verschwindet, haben wir $\frac{p(X)}{q(X)} = 1$, deswegen, nach Multiplikation mit $q(X)$ auf beiden Seiten der Gleichung, erhalten wir: $p(X) = q(X)$.

5 Hauptresultate Betreffs Typizität

Im folgenden Satz zeigen wir, dass die Wahrscheinlichkeit einer von einer DEQ produzierten Folge durch die Entropie ihres Typs und relative Entropie ihres Typs bzgl. unserer generischen Verteilung dargestellt werden kann:

Satz 1 [2]: für $x \in E^n$, das gemäß einer DEQ mit generischer Verteilung Q und Quellenalphabet E produziert wird, hängt die Wahrscheinlichkeit der Folge $Q^n(x)$ lediglich von dem Typ P_x von x ab, und ist gegeben durch:

$$Q^n(x) = 2^{-n(H(P_x) + D(P_x||Q))}. \quad (5.1)$$

Anmerkung: im Folgenden wird $2^{(\dots)}$ als $\exp(\dots)$ bezeichnet

Beweis:

$$Q^n(x) = \prod_{i=1}^n Q(x_i) = \prod_{a \in E} Q(a)^{N(a|x)} = \prod_{a \in E} Q(a)^{nP_x(a)} = \exp \left(\sum_{a \in E} nP_x(a) \log Q(a) \right) =$$

$$\begin{aligned}
& \exp \left(\sum_{a \in E} n(P_x(a) \log Q(a) + P_x(a) \log P_x(a) - P_x(a) \log P_x(a)) \right) = \\
& \exp \left(\sum_{a \in E} n \left(P_x(a) \log \frac{Q(a)}{P_x(a)} + P_x(a) \log P_x(a) \right) \right) = \\
& \exp \left(n \left(\sum_{a \in E} -P_x(a) \log \frac{P_x(a)}{Q(a)} + \sum_{a \in E} P_x(a) \log P_x(a) \right) \right) = \exp(n(-H(P_x) - D(P_x||Q))).
\end{aligned}$$

□

Es macht Sinn, dass der Typ einer Folge ihre Wahrscheinlichkeit eindeutig bestimmt, da das Produktmaß $Q^n((X_1, \dots, X_n) = x) = Q^n((X_1, \dots, X_n) = \pi(x))$ blind für jegliche Permutation u.i.v. Variablen ist, und da die einzige zu erlangende Information, indem man die genaue Folge x anstatt ihres Typs hat, ihre Permutation ist. Aus diesem Resultat ziehen wir ein schönes Korollar falls x Typ Q hat:

Korollar 2 [2]: falls der Typ einer Folge $x \in E^n$, welche gemäß einer DEQ mit generischer Verteilung Q und Quellenalphabet E produziert wird, Q ist, dann:

$$Q^n(x) = 2^{-nH(Q)}. \quad (5.2)$$

Beweis: Unmittelbar durch die positiv-Definiertheit der Kullback-Leibler Divergenz nachdem man in (5.1) Q für P_x einsetzt. □

Diese Resultate erlauben uns, Schranken von Mächtigkeiten von Typklassen zu setzen:

Satz 3 [2]: Falls $P \in \mathcal{P}_n$, dann:

$$\frac{2^{nH(P)}}{(n+1)^{|E|}} \leq |T(P)| \leq 2^{nH(P)}. \quad (5.3)$$

Anmerkung: Den genauen Wert von $|T(P)|$ zu finden ist eigentlich nicht zu schwer. Er ist einfach der Multinomialkoeffizient:

$$\binom{n}{N(a_1|x), \dots, N(a_{|E|}|x)}$$

wo $\{a_i\}_{i=1}^{|E|}$ eine Abzählung von E und x eine Folge in $T(P)$ sind. Dass dies tatsächlich die Mächtigkeit von $T(P)$ ist ist offenbar, da alles was wir machen möchten ist $N(a_1|x), \dots, N(a_{|E|}|x)$ in einer Folge anordnen (ohne Unterschiedungen zwischen den $N(a_i|x)$ Objekten zu machen). Durch die Definition von $N(a|x)$ können wir auch einen Ausdruck ohne unsere Folge x erhalten:

$$\binom{n}{nP(a_1), \dots, nP(a_{|E|})}$$

Das Problem an diesem Wert ist, dass er etwas schwierig zu handhaben ist. Wir arbeiteten viel lieber mit einem Exponenten, was zur Motivation für die Suche nach exponentiellen Schranken von $|T(P)|$ führt.

Wir beachten zunächst, dass wir eine polynomiale obere Schranke von $|\mathcal{P}_n|$ setzen können, welche, wenngleich grob, unseren Bedürfnissen taugen wird:

Lemma 4 [2]:

$$|\mathcal{P}_n| \leq (n+1)^{|E|}. \quad (5.4)$$

Beweis (Lemma 4): Man bemerkt leicht, dass für ein gegebenes $P \in \mathcal{P}_n$, P auf $|E|$ Elemente abbildet und jedem Element einen Wert in $\{\frac{i}{n}\}_{i=0}^n$ zuordnen kann. Dementsprechend:

$$|\mathcal{P}_n| \leq (n - 0 + 1)^{|E|} = (n + 1)^{|E|}.$$

□

Anmerkung: Natürlich kann man diese obere Schranke feiner machen. z. B., falls Ω unser Grundraum ist, kann man bemerken, dass $1 = P(\Omega) = P\left(\bigcup_{i=1}^{|E|} \omega_i\right) = \sum_{i=1}^{|E|} P(\omega_i)$, da Wahrscheinlichkeitsmaße σ -additiv sind. Demnach, falls wir alle bis auf ein Element Wahrscheinlichkeiten zugewiesen haben, müsste das letzte Element Wahrscheinlichkeit $P(\omega_{|E|}) = 1 - \sum_{i=1}^{|E|-1} P(\omega_i)$ haben, was bedeutet, dass wir eine bessere Schranke $(n + 1)^{|E|-1}$ von $|\mathcal{P}_n|$ setzen können. Man könnte dieses Verfahren für alle bis auf zwei Elemente usw. fortsetzen. Uns, allerdings, wird es nur wichtig sein, dass diese Schranke nicht schneller als ein Polynom wächst wenn $n \rightarrow \infty$. Nun zum Beweis von Satz 3:

Beweis (Satz 3): für die obere Schranke von $|T(P)|$ haben wir:

$$1 \geq P^n(T(P)) = \sum_{x \in T(P)} P^n(x) \stackrel{(5.2)}{=} \sum_{x \in T(P)} 2^{-nH(P)} = |T(P)| 2^{-nH(P)}.$$

Nach Multiplikation auf beiden Seiten mit $2^{nH(P)}$, erhalten wir unsere obere Schranke. Für die andere Richtung beweisen wir zunächst, dass $P^n(T(Q))$ maximiert wird wenn $Q = P$. Dafür betrachten wir folgenden Quotienten und zeigen, dass er größer gleich 1 ist:

$$\begin{aligned} \frac{P^n(T(P))}{P^n(T(Q))} &= \frac{\sum_{x \in T(P)} P^n(x)}{\sum_{x \in T(Q)} P^n(x)} \stackrel{\text{u.i.v.}}{=} \frac{\sum_{x \in T(P)} \prod_{i=1}^n P(x_i)}{\sum_{x \in T(Q)} \prod_{i=1}^n P(x_i)} = \frac{\sum_{x \in T(P)} \prod_{a \in E} P(a)^{N(a|x)}}{\sum_{x \in T(Q)} \prod_{a \in E} P(a)^{N(a|x)}} = \\ \frac{\sum_{x \in T(P)} \prod_{a \in E} P(a)^{nP(a)}}{\sum_{x \in T(Q)} \prod_{a \in E} P(a)^{nQ(a)}} &= \frac{|T(P)| \prod_{a \in E} P(a)^{nP(a)}}{|T(Q)| \prod_{a \in E} P(a)^{nQ(a)}} \stackrel{\text{Anm.}}{=} \frac{\binom{n}{nP(a_1), \dots, nP(a_{|E|})}}{\binom{n}{nQ(a_1), \dots, nQ(a_{|E|})}} \prod_{a \in E} P(a)^{n(P(a)-Q(a))} = \\ &\prod_{a \in E} \frac{(nQ(a))!}{(nP(a))!} P(a)^{n(P(a)-Q(a))}. \end{aligned}$$

Wir verwenden nun, dass $\frac{m!}{n!} \geq n^{m-n}$, da falls $m \geq n$:

$$\frac{m!}{n!} = m(m-1) \cdots (m-n+1) \geq n^{m-n},$$

und falls $m < n$:

$$\frac{m!}{n!} = \frac{1}{n(n-1) \cdots (n-m+1)} \geq \frac{1}{n^{n-m}} = n^{m-n}.$$

Folglich:

$$\begin{aligned} \prod_{a \in E} \frac{(nQ(a))!}{(nP(a))!} P(a)^{n(P(a)-Q(a))} &\geq \prod_{a \in E} (nP(a))^{n(Q(a)-P(a))} P(a)^{n(P(a)-Q(a))} = \prod_{a \in E} n^{n(Q(a)-P(a))} = \\ &n^{\sum_{a \in E} n(Q(a)-P(a))} = n^{n(1-1)} = 1, \end{aligned}$$

wo wir in der zweitletzten Gleichheit beachten, dass $\sum_{a \in E} P(a) = \sum_{a \in E} Q(a) = 1$, denn P und Q sind Wahrscheinlichkeitsmaße und wir summieren über eine Partition unseres Quellenalphabets E . Wenn wir das wissen, können wir argumentieren (unter Verwendung der Tatsache, dass unsere Typklassen E^n unterteilen):

$$\begin{aligned} 1 &= \sum_{Q \in \mathcal{P}_n} P^n(T(Q)) \leq \sum_{Q \in \mathcal{P}_n} P^n(T(P)) \stackrel{(5.4)}{\leq} (n+1)^{|E|} P^n(T(P)) = (n+1)^{|E|} \sum_{x \in T(P)} P^n(x) \stackrel{(5.2)}{=} \\ &(n+1)^{|E|} \sum_{x \in T(P)} 2^{-nH(P)} = (n+1)^{|E|} |T(P)| 2^{-nH(P)}. \end{aligned}$$

Multiplikation auf beiden Seiten mit $\frac{2^{nH(P)}}{(n+1)^{|E|}}$ liefert unsere untere Schranke. $\square$

Dies führt uns zu einem Korollar, welches uns später erlauben wird, unsere in der Einführung erwähnte exponentielle Schranke zu erringen:

Korollar 5 [2]: für Verteilungen $P \in \mathcal{P}_n$ und Q :

$$\frac{2^{-nD(P||Q)}}{(n+1)^{|E|}} \leq Q^n(T(P)) \leq 2^{-nD(P||Q)}. \quad (5.5)$$

Beweis:

$$Q^n(T(P)) = \sum_{x \in T(P)} Q^n(x) \stackrel{(5.1)}{=} \sum_{x \in T(P)} 2^{-n(H(P)+D(P||Q))} = |T(P)| 2^{-n(H(P)+D(P||Q))}.$$

Indem wir unsere Schranken für $|T(P)|$ aus Satz 3 einsetzen, erhalten wir die gewünschten Ungleichheiten. $\square$

6 Entropie als Unsicherheit

Wir sind endlich in der Position, die im Abschnitt 2 angespielte Motivation zu besprechen. Es wurde erwähnt, dass Entropie ein Maß der „Unsicherheit“ einer Zufallsvariable X sein soll, aber wie, mathematisch, können wir beschreiben, was Unsicherheit bedeutet? Als Beispiel, wenn wir $E := \{0, 1\}$ als unser Quellenalphabet hinnehmen, wir könnten vielleicht $X \sim \text{Ber}(0.99)$ für sicherer als $Y \sim \text{Ber}(\frac{1}{2})$ erachten, denn wir können zuversichtlicher sein, dass X 1 sein wird als dass Y jeglicher festgelegener Wert ist. Und zwar, wenn wir Unsicherheit als Unvorhersagbarkeit verstehen und versuchen, das Aussehen von gemäß jeweils $\text{Ber}(0.99)$ und $\text{Ber}(\frac{1}{2})$ produzierten Folgen $x, y \in \{0, 1\}^n$ vorherzusagen, wir bemerkten vielleicht, dass wir mit mehr Sicherheit von unserer Vorhersage für x eine größere Anzahl an möglichen Folgen in $\{0, 1\}^n$ ausschließen können: Wir können zuerst bemerken, nach dem (starken) Gesetz der großen Zahlen, für die Zufallsvariable $Z \sim (\text{Ber}(p))^n$ und für alle $\epsilon > 0$ gilt:

$$0 = Wkeit \left[\lim_{n \rightarrow \infty} \left(\frac{\sum_{i=1}^n Z_i}{n} \right) - E[\text{Ber}(p)] \geq \epsilon \right] = Wkeit \left[\lim_{n \rightarrow \infty} \left(\frac{|\{i \in [1, n]_{\mathbb{N}} | Z_i = 1\}|}{n} \right) - p \geq \epsilon \right], \quad (6.1)$$

wo wir $\{1, 2, \dots, n\}$ mit $[1, n]_{\mathbb{N}}$ bezeichnen. Also für großes n , erhalten wir mit Wahrscheinlichkeit annähernd 1, dass ungefähr 99% der Elemente in unserer Folge x und ein halb dessen in y Einsern sein werden, was heißt, dass die Typen P_x von x und P_y von y „ungefähr“ gleich jeweils $\text{Ber}(0.99)$ und $\text{Ber}(\frac{1}{2})$ sein werden. Wir werden sogar zeigen, dass für $n \rightarrow \infty$ und für alle $\epsilon > 0$, $P_x \notin \{Q | D(Q || \text{Ber}(0.99)) > \epsilon\}$ mit Wahrscheinlichkeit 1 (genauso für y). d. H., dass im Grenzfalle, Folgen in Typklassen verschieden von $T(\text{Ber}(0.99))$ können als plausible Vorhersagen für x ausgeschlossen werden. Dies lässt uns mit den Folgen in $T(\text{Ber}(0.99))$ als gute Wahlen für Vorhersagen über wie x aussehen wird. Indem wir ähnliche Logik für y anwenden, sehen wir, dass uns Folgen in $T(\text{Ber}(\frac{1}{2}))$ übrig bleiben. Da, allerdings, das Vorkommen jeder Folge in $T(\text{Ber}(0.99))$ gleich wahrscheinlich ist, könnten wir die Anzahl an „guten“ Wahlen $|T(\text{Ber}(0.99))|$ für Vorhersagen über x als die „Unvorhersagbarkeit“ und dementsprechend „Unsicherheit“ des Aussehens von x auffassen (genauso für y).

Überall im obigen Aufsatz haben wir an einer unbesonnenen Annahme von n in der Nähe vom Unendlichen festgehalten, um an einem Zusammenhang zwischen der Unsicherheit einer Folge unserer Bernoullivariablen und den Mächtigkeiten der Typklassen der jeweiligen Verteilungen anzukommen. Dennoch müssen wir dies irgendwie rigoros formulieren, denn wenn wir fordern, dass unser Unsicherheitsmaß additiv ist, eine vielleicht begehrenswerte Eigenschaft, ergibt sich ein unwohldefiniertes Objekt. Wenn wir versuchen, einen Mittelwert zu finden und eine durchschnittliche Unsicherheit eines Folgenglieds zu beschaffen, erhalten wir $\frac{|T(\cdot)|}{n}$, was divergiert wenn n wächst (wir berechnen einen Durchschnitt, denn die Folgen $x \in E^n$ zu betrachten entspricht der Unsicherheit der Zufallsvariable $X \sim P^n$ wohingegen Glieder zu betrachten jener der Zufallsvariable $X \sim P$ entspricht). Dies wird

ersichtlich, nachdem man bemerkt, dass wenn $n \rightarrow \infty$ die Größen der Typklassen $|T(\text{Ber}(0.99))|$ und $|T(\text{Ber}(\frac{1}{2}))|$, bspw., gemäß ihres jeweiligen Multinomial- (in diesem Fall Binomial-) Koeffizienten explodieren und diese Werte sind natürlich nicht in $O(n)$. Deshalb möchten wir eine Funktion finden, welche mit $|T(P)|$ wächst, wobei wir n festhalten, während sie trotzdem das Wachstum von $|T(P)|$ mit n mäßigt, so dass unser neuer Wert in $O(n)$ ist und wir den Durchschnitt berechnen können. Da wir wissen, dass $|T(P)|$ exponentiell wächst, könnten wir vielleicht einen Logarithmus in Betracht ziehen, was zu $\frac{\log |T(P)|}{n}$ als unser Unsicherheitsmaß führt. Nun aber, da $\frac{\log(\cdot)}{n}$ streng monoton wachsend ist, nach Satz 3:

$$\frac{\log \left(\frac{2^{nH(P)}}{(n+1)^{|E|}} \right)}{n} \leq \frac{\log |T(P)|}{n} \leq \frac{\log(2^{nH(P)})}{n},$$

da streng monoton wachsende Funktionen Ungleichungen nicht verändern. Die rechte Seite lässt sich zur Entropie von P vereinfachen und:

$$\frac{\log \left(\frac{2^{nH(P)}}{(n+1)^{|E|}} \right)}{n} = H(P) - |E| \frac{\log(n+1)}{n}. \quad (6.2)$$

Wir sehen jetzt, dass, für $n \rightarrow \infty$, der Term rechts auf der rechten Seite von (6.2) gegen Null konvergiert, was bedeutet, dass unsere Ungleichungen zur Entropie $H(P)$ zusammenquetschen wenn wir Limes nehmen und:

$$\lim_{n \rightarrow \infty} \frac{\log |T(P)|}{n} = H(P). \quad (6.3)$$

In so einem Fall, schreiben manche Autoren $|T(P)| \doteq 2^{nH(P)}$, um zu sagen, dass $|T(P)|$ und $2^{nH(P)}$ „zur ersten Ordnung im Exponenten übereinstimmen“. Genauer [2]:

$$a_n \doteq b_n \iff \lim_{n \rightarrow \infty} \frac{1}{n} \log \frac{a_n}{b_n} = 0. \quad (6.4)$$

Das bedeutet, dass das Unsicherheitsmaß, welches wir nach ein Paar logischen Überlegungen über wie es funktionieren soll vorgeschlagen haben genau die von uns im Abschnitt 2 definierte Entropie ist. Diese Interpretation der Entropie ist mit der asymptotischen Equipartitionseigenschaft eng verbunden, was im nächsten Abschnitt besprochen werden wird. Unterdessen, beweisen wir die im Absatz unter (6.1) gemachte Behauptung, dass für $n \rightarrow \infty$ und für alle $\epsilon > 0$, $P_x \notin \{Q | D(Q || \text{Ber}(0.99)) > \epsilon\}$ mit Wahrscheinlichkeit eins. Dafür werden wir den Begriff einer (ϵ) -typischen Menge brauchen:

$$T_Q^{\epsilon, n} := \{x \in E^n | D(P_x || Q) \leq \epsilon\},$$

was jene Folgen x darstellt, wessen Typen bzgl. der Kullback-Leibler Divergenz nicht mehr als ϵ von Q abweichen. Das bedeutet, dass die Folgen, welche wir früher erwähnt haben, durch die Menge $(T_{\text{Ber}(0.99)}^{\epsilon})^c$ beschrieben werden können. Wie im vorigen Satz wird das n im oberen Index manchmal ausgelassen. Die Folgen in der typischen Menge heißen ϵ -schwach typisch (oder einfach „schwach typisch“), allerdings, da diese Arbeit starke Typizität [3] nicht besprechen wird, was zusätzlich einen endlichen Träger verlangt, wir werden sie einfach als typisch/ ϵ -typisch bezeichnen. Nun zum Beweis der Aussage, welche wir gemacht haben:

Satz 6 [2]: Für alle $\epsilon > 0$ und Verteilungen Q :

$$Wkeit((T_Q^{\epsilon})^c) \leq (n+1)^{|E|} 2^{-n\epsilon}.$$

Beweis:

$$\begin{aligned} Wkeit((T_Q^{\epsilon, n})^c) &= \sum_{P \in \mathcal{P}_n : D(P || Q) > \epsilon} Q^n(T(P)) \stackrel{(5.5)}{\leq} \sum_{P \in \mathcal{P}_n : D(P || Q) > \epsilon} 2^{-nD(P || Q)} \leq \sum_{P \in \mathcal{P}_n : D(P || Q) > \epsilon} 2^{-n\epsilon} \stackrel{(5.4)}{\leq} \\ &= (n+1)^{|E|} 2^{-n\epsilon}. \end{aligned}$$

□

Dass dies unsere Behauptung impliziert, dass $\lim_{n \rightarrow \infty} Wkeit((T_Q^{\epsilon, n})^c) = 0$ ist offenbar, denn 2^{-n} konvergiert schneller als jegliches Polynom divergiert. Wir erhalten folgendes Korollar:

Korollar 7 [2]: Seien $X_1, X_2, \dots$ eine DEQ mit generischer Verteilung Q , dann:

$$D(P_{X^n} || Q) \rightarrow 0 \text{ fast sicher (f.s.),}$$

wobei P_{X^n} den Typ der zufälligen Folge $(X_1, X_2, \dots, X_n)$ bezeichnet.

Beweis: wir haben:

$$\sum_{n \in \mathbb{N}} Wkeit(D(P_{X^n} || Q) > \epsilon) = \sum_{n \in \mathbb{N}} Wkeit((T_Q^{\epsilon, n})^c) \leq \sum_{n \in \mathbb{N}} 2^{-n(\epsilon - |E| \frac{\log(n+1)}{n})}, \quad (6.5)$$

und:

$$\limsup_{n \rightarrow \infty} \left(2^{-n(\epsilon - |E| \frac{\log(n+1)}{n})} \right)^{\frac{1}{n}} = \limsup_{n \rightarrow \infty} 2^{\frac{-n\epsilon}{n}} (n+1)^{\frac{|E|}{n}} = 2^{-\epsilon}$$

ist für alle festen $\epsilon > 0$ streng kleiner als eins. In der letzten Gleichheit haben wir verwendet, dass für alle Polynome $p \in \mathbb{R}[x]$, $\lim_{n \rightarrow \infty} |p(n)|^{\frac{1}{n}} = 1$, wobei dies geprüft werden kann, indem man die Regel von de L'Hôpital [8] auf den Logarithmus des Limes anwendet und dann wiederpotenziert. Wir können nun das Wurzelkriterium von Cauchy verwenden, um zu folgern, dass unsere Reihe konvergiert. Wir entsinnen uns des ersten Borel-Cantelli Lemmas [6, 7]:

$$\sum_{n \in \mathbb{N}} Wkeit(E_n) < \infty \implies Wkeit\left(\limsup_{n \rightarrow \infty} E_n\right) = 0,$$

wo $E_1, E_2, \dots$ Ereignisse sind. In Worten, falls die erwartete Anzahl an Vorkommnissen der Ereignisse E_i endlich ist, dann ist die tatsächliche Anzahl an Vorkommnissen fast sicher auch endlich. Da unsere Summe in (6.5) endlich ist, trifft das Borel-Cantelli Lemma zu und: $Wkeit(\limsup_{n \rightarrow \infty} [D(P_X || Q) > \epsilon]) = 0$. Also, $D(P_{X^n} || Q) \xrightarrow{a.s.} 0$. $\square$

7 Die Asymptotische Equipartitionseigenschaft

Im Korollar 7 haben wir gesehen, dass der Typ P_X einer von einer DEQ produzierten zufälligen Folge in jenem Sinne zunehmend deterministisch wird, dass P_X mit Wahrscheinlichkeit eins mehr und mehr wie unsere generische Verteilung P aussieht. Im Satz 1 haben wir auch gesehen, dass $Q^n(x) = 2^{-n(H(P_x) + D(P_x || Q))}$ aber da der zweite Term im Exponenten gegen Null geht würde man erwarten, dass die Wahrscheinlichkeit einem Ausdruck annähern wird, welcher lediglich von $H(Q)$ abhängt. Dies ist, tatsächlich, ein grundlegendes Resultat in der Informationstheorie:

Satz 8, asymptotische Equipartitionseigenschaft (oftmals AEP, auch wegen des englischen Namens „asymptotic equipartition property“) [9]: falls $X_1, X_2, \dots$ eine DEQ mit generischer Verteilung Q ist, dann:

$$-\frac{1}{n} \log Q^n(X_1, X_2, \dots, X_n) \xrightarrow{f.s.} H(Q). \quad (7.1)$$

Anmerkung: Dies folgt geradewegs aus Korollar 7, (5.1), (5.2) und (6.3) aber da dieses Resultat so eine intime Verbindung mit dem Gesetz der großen Zahlen hat (es wird oft sogar „das Gesetz der großen Zahlen der Informationstheorie“ geheißen), werden wir jene Verbindung in unserem Beweis veranschaulichen:

Beweis: als Funktion u.i.v. Variablen sind:

$$Y_i := -\log Q(X_i)$$

auch u.i.v. und:

$$\begin{aligned}
-\frac{1}{n} \log Q^n(X_1, X_2, \dots, X_n) &= -\frac{1}{n} \log(Q(X_1)Q(X_2) \cdots Q(X_n)) = \\
&= -\frac{1}{n} (\log Q(X_1) + \log Q(X_2) + \cdots + \log Q(X_n)) = \bar{Y}_n,
\end{aligned}$$

wobei $\bar{Y}_n$ den empirischen Durchschnitt der ersten n Y_i bezeichnet. Nun, nach dem starken Gesetz der großen Zahlen [10]:

$$\bar{Y}_n \xrightarrow{f.s.} E[Y_1] = -E[\log(X_1)] = H(X) = H(Q).$$

□

Anmerkung: man kann auch Konvergenz im ersten Mittel zeigen (Satz von Shannon-McMillan-Breiman [11]):

$$E \left[\left| \lim_{n \rightarrow \infty} -\frac{1}{n} \log Q^n(X_1, X_2, \dots, X_n) - H(Q) \right| \right] = 0,$$

aber diese Arbeit verzichtet auf den Beweis jenes Resultats, da es nicht in unserem Rahmen liegt.

8 Ungleichung und Satz der großen Abweichungen von Sanov

Die in der Einführung erwähnte Schranke folgt leicht aus Korollar 5 und Satz 6:

Satz 9, Sanov'sche Ungleichung [2, 17]: seien $X_1, X_2, \dots$ eine DEQ mit generischer Verteilung Q und Quellenalphabet E . Sei überdies $\mathcal{A}$ eine Menge von Verteilungen, dann:

$$Q^n(\cup_{P \in \mathcal{A} \cap \mathcal{P}_n} T(P)) \leq (n+1)^{|E|} 2^{-nD(P^*||Q)}, \quad (8.1)$$

wo $P^* := \operatorname{argmin}_{P \in \operatorname{cl}(\mathcal{A})} D(P||Q)$.

Anmerkungen:

- Wenn $Q \in \mathcal{A}$, wird die Ungleichung uninteressant, denn sie vereinfacht sich auf eine Wahrscheinlichkeit, welche durch ein Polynom beschränkt wird. Von nun an nehmen wir daher an, dass Q nie in $\mathcal{A}$ liegt.
- Wir schreiben $Q^n(T(\mathcal{A} \cap \mathcal{P}_n))$ um $Q^n(\cup_{P \in \mathcal{A} \cap \mathcal{P}_n} T(P))$ zu bezeichnen. Wir könnten das weiter auf $Q(T(\mathcal{A}))$ vereinfachen.
- Mit $\operatorname{cl}(\mathcal{A})$ meinen wir den Abschluss von $\mathcal{A}$ hinsichtlich der schwachen Topologie auf Wahrscheinlichkeitsmaßen. Siehe die Erörterung im Absatz vor Satz 10.

Beweis: siehe Beweis von Satz 6 und setze $\epsilon := D(P^*||Q)$.

Interpretation: diese Ungleichung besagt uns, dass der Wahrscheinlichkeit, dass $x \in E^n$ in einer gewissen Menge B ist, eine obere Schranke gegeben werden kann, welche lediglich von jenem Element y mit Typ „am nächsten“ an der generischen Verteilung Q bzgl. der Kullback-Leiber Divergenz abhängt. Des Weiteren, wenn der Typ von y nicht die generische Verteilung Q ist, dann haben wir eine in n exponentiell abfallende Wahrscheinlichkeit. Im Sanov'schen Satz über große Abweichungen werden wir sogar sehen, dass jene Wahrscheinlichkeit und ihre Schranke zur ersten Ordnung im Exponenten übereinstimmen (6.4) falls eine gewisse Bedingung an $\mathcal{A}$ hält. Jene Übereinstimmung heißt, dass wir in (8.1) keinen besseren Exponenten als $-nD(P^*||Q)$ finden können.

Die oben genannte Bedingung wird sein, dass „ $\mathcal{A}$ der Abschluss seines Inneren“ bzgl. der „schwachen Topologie“ auf unseren Wahrscheinlichkeitsmaßen ist. Die schwache Topologie ist, im Grunde, die schwächste (kleinste) Topologie auf dem Raum unserer Wahrscheinlichkeitsmaße $\mathcal{P}(\Omega)$, so dass alle Funktionale in unserem Dualraum $\mathcal{P}(\Omega)^*$ stetig bleiben. Ins. in der schwachen Topologie auf Wahrscheinlichkeitsmaßen, eine Folge P_n konvergiert genau dann gegen ein Maß P , wenn für alle Funktionen

$f \in C_b(\Omega)$, welche auf unserem Grundraum Ω stetig und beschränkt sind, $\int_{\Omega} f dP_n$ gegen $\int_{\Omega} f dP$ konvergiert, wobei $\int_{\Omega} f dP_{(n)}$ das Lebesgue-Integral von f bzgl. des Maßes $P_{(n)}$ ist [15]. Dies hat auch eine Verbindung mit der Lévy-Prokhorov Metrik aber diese Arbeit wird nicht detaillierter darauf eingehen. Siehe bitte [12, 13].

Was uns diese Bedingung im Wesentlichen zu tun erlaubt, ist sicherzustellen, dass P^* in $\mathcal{A}$ liegt, da $\mathcal{A}$ abgeschlossen ist, und dass $\mathring{\mathcal{A}}$ nicht leer ist, so dass jede Verteilung in $\mathcal{A}$ durch andere auch in $\mathcal{A}$ approximiert werden kann (siehe Beweis unten).

Satz 10, Sanov'sche Satz über große Abweichungen [2, 17]: seien $X_1, X_2, \dots$ eine DEQ mit generischer Verteilung Q und Quellenalphabet E . Sei außerdem $\mathcal{A}$ eine Menge von Verteilungen mit $\mathcal{A} = cl(\mathring{\mathcal{A}})$ bzgl. der schwachen Topologie, dann:

$$\lim_{n \rightarrow \infty} \log \frac{Q^n(T(\mathcal{A}))}{n} = -D(P^* || Q).$$

Beweis:

$$Q^n(T(\mathcal{A})) = \sum_{P \in \mathcal{A} \cap \mathcal{P}_n} Q^n(T(P)) \geq Q^n(T(P_n)) \stackrel{(5.5)}{\geq} \frac{2^{-nD(P_n || Q)}}{(n+1)^{|E|}}, \quad (8.2)$$

wobei, da P^* durch Verteilungen in $\mathcal{A} \setminus \{P^*\}$ approximiert werden kann (denn $\mathcal{A} = cl(\mathring{\mathcal{A}})$), und da $\cup_{n \in \mathbb{N}} \mathcal{P}_n$ dicht in der Menge aller Verteilungen ist, können wir $P_i \in \mathcal{P}_i$ für alle i finden, so dass $\lim_{i \rightarrow \infty} P_i = P^*$. Demnach, da:

$$\lim_{n \rightarrow \infty} \frac{\log \frac{2^{-nD(P_n || Q)}}{(n+1)^{|E|}}}{n} = -D(P^* || Q) = \lim_{n \rightarrow \infty} \frac{\log 2^{-nD(P_n || Q)}}{n},$$

wir sehen, dass unsere obere Schranke (8.1) und unsere untere Schranke (8.2) zur ersten Ordnung im Exponenten übereinstimmen. $\square$

Anmerkung: unsere Beweise für die Sanov'sche Ungleichung und den Sanov'schen Satz über große Abweichungen waren für diskrete erinnerungslose Quellen. Nichtsdestotrotz halten diese Resultate auch im kontinuierlichen Rahmen und können durch Quantisierung bewiesen werden [18].

Wenn wir auf unser Beispiel mit $Ber(\frac{1}{2})$ zurückschauen wird es logisch, dass die Wahrscheinlichkeit einer Menge $B := \{x \in \cup_{n \in \mathbb{N}} E^n | \text{mindestens drei Drittel von } x \text{ sind Einsen}\}$ z. B., zunehmend weniger abhängig von Folgen x mit einem Verhältnis von $\frac{3}{4} + \epsilon$ von Einsen zu Nullen, denn ihre Wahrscheinlichkeit fallen exponentiell schneller ab als jene mit einem Verhältnis von $\frac{3}{4}$ (die Typen des Vorherigen haben eine größere Kullback-Leibler Divergenz bzgl. $Ber(\frac{1}{2})$, siehe: (5.1)).

9 Anwendungen der Sanov'schen Ungleichung

Die Sanov'sche Ungleichung erlaubt es uns, unsere Suche nach einer Wahrscheinlichkeitsschranke auf ein konkretes Minimierungsproblem zurückzuführen, was, in vielen Fällen, ein handhabbareres ist. In vielen Anwendungen möchte man einer Wahrscheinlichkeit der Form [2]:

$$Wkeit \left(\bigcap_{j=1}^k \left(\frac{1}{n} \sum_{i=1}^n f_j(X_i) \geq c_j \right) \right), \quad (9.1)$$

eine Schranke geben, wo f_j gegebene reell-wertige Funktionen ($\mathbb{R} \rightarrow \mathbb{R}$), c_j gegebene Konstanten, und $X_1, X_2, \dots, X_n$ Zufallsvariablen sind, welche gemäß der DEQ mit generischer Verteilung Q und Quellenalphabet E produziert werden. Für eine gegebene Folge x mit Typ $P_x \in \mathcal{P}_n$, bemerken wir, dass die Summe in (9.1) nicht anders als:

$$E_{P_x}[f_j(Y)] = \sum_{a \in E} P_x(a) f_j(a) = \sum_{a \in E} \frac{N(a|x)}{n} f_j(a) = \frac{1}{n} \sum_{i=1}^n f_j(x_i) = (9.1),$$

ist, wo $E_{P_x}[\cdot]$ der Erwartungswert bzgl. des entsprechenden Maßes P_x und $Y \sim P$ eine Zufallsvariable mit entsprechender Massenfunktion P_x sind. Dementsprechend, eine Folge $x \in E^n$ ist genau dann innerhalb der Menge¹ in (9.1), wenn ihr Typ $P_x \sum_{a \in E} P_x(a) f_j(a) \geq c_j$ erfüllt. Dementsprechend, im Rahmen des Satzes 9 (Sanov'scher Ungleichung), unsere Menge $\mathcal{A}$ kann als:

$$\mathcal{A} := \left\{ P \in \mathcal{P} \left| \forall j \in [1, k]_{\mathbb{N}} \sum_{a \in E} P(a) f_j(a) \geq c_j \right. \right\}, \quad (9.2)$$

geschrieben werden, wobei $\mathcal{P} := \cup_{i \in \mathbb{N}} \mathcal{P}_n$. Um die Sanov'sche Schranke von (9.1) zu finden, sagt die Sanov'sche Ungleichung aus, dass wir zunächst P^* , was in $\bar{\mathcal{A}} = \mathcal{A}$ ist, finden müssen, das an der zugrundeliegenden generischen Verteilung Q am nächsten liegt. d. H., wir müssen den Typ $P^* \in \mathcal{A}$ finden, welcher die Kullback-Leibler Divergenz minimiert. Um dies zu tun, konstruieren wir folgendes Funktional unter Verwendung von Lagrange'schen Multiplikatoren [14]:

$$\begin{aligned} \mathcal{F}(P) &:= D(P||Q) + \sum_{j=1}^k \lambda_j \sum_{a \in E} P(a) f_j(a) + \nu \sum_{a \in E} P(a) = \\ &\sum_{a \in E} P(a) \log \frac{P(a)}{Q(a)} + \sum_{j=1}^k \lambda_j \sum_{a \in E} P(a) f_j(a) + \nu \sum_{a \in E} P(a) \end{aligned}$$

in welchem unsere Bedingungen in (9.2) widergespiegelt werden. Zusätzlich repräsentiert der letzte Term die Bedingung, dass P ein Wahrscheinlichkeitsmaß sein muss. i.a.W. $\sum_{a \in E} P(a) \stackrel{!}{=} 1$.

Wir möchten nun partielle Ableitungen nach $P(y)$ finden, um zu bestimmen, für welche Werte $P(a)$ wir haben, dass $\mathcal{F}$ ein Extremum hat. Diese partielle Differenzierung nach $P(y)$ bedeutet, dass wir $\mathcal{F}$ als nur von $P(y)$ abhängige Funktion auffassen. d. H., für alle andere $a \in E \setminus \{y\}$, wird $P(a)$ als Konstante betrachtet, denn der Ausgang einer Funktion ausgewertet an einem gewissen Punkt verändert sich nicht mit dem Ausgang ausgewertet an einem anderen, also $\frac{\partial P(a)}{\partial P(y)} = 0$. Dies ist weil, zu diesem Zeitpunkt, P noch eine allgemeine Funktion ist. Für Wahrscheinlichkeitsverteilungen gibt es natürlich Abhängigkeit zwischen den $P(a)$, da sie sich zu eins summieren müssen, aber wir können immer apostepriori was auch immer für einen Wert unsere Summe ergibt gutmachen, indem wir ν geeignet anpassen. Deswegen, nach Linearität der partiellen Ableitung:

$$\begin{aligned} \frac{\partial \mathcal{F}}{\partial P(y)} &= \frac{\partial}{\partial P(y)} \left[\sum_{a \in E} P(a) \log \frac{P(a)}{Q(a)} + \sum_{j=1}^k \lambda_j \sum_{a \in E} P(a) f_j(a) + \nu \sum_{a \in E} P(a) \right] = \\ &\sum_{a \in E} \frac{\partial}{\partial P(y)} \left[P(a) \log \frac{P(a)}{Q(a)} \right] + \sum_{j=1}^k \lambda_j \sum_{a \in E} \frac{\partial}{\partial P(y)} [P(a) f_j(a)] + \nu \sum_{a \in E} \frac{\partial}{\partial P(y)} [P(a)] = \\ &\sum_{a \in E} \left(\delta_{a,y} \left(Q(a) + \log \frac{P(a)}{Q(a)} \right) \right) + \sum_{j=1}^k \lambda_j \sum_{a \in E} \delta_{a,y} f_j(a) + \nu \sum_{a \in E} \delta_{a,y} = \\ &1 + \log \frac{P(y)}{Q(y)} + \sum_{j=1}^k \lambda_j f_j(y) + \nu, \end{aligned} \quad (9.3)$$

wo $\delta_{a,y}$ das Kronecker-Delta ist:

$$\delta_{a,y} := \begin{cases} 1, & a = y \\ 0, & a \neq y \end{cases}$$

Indem wir (9.3) gleich Null setzen und nach $P(y)$ auflösen, erringen wir:

$$P(y) = Q(y) 2^{-\nu-1-\sum_{j=1}^k \lambda_j f_j(y)}.$$

¹was in der Wahrscheinlichkeitsfunktion ist

Wir können auch beachten, dass Division unseres Ausdruckes durch die Summe aller $P(y)$ unsere Bedingung gewährleistet, dass P eine Wahrscheinlichkeitsmassenfunktion sein muss, wodurch die Notwendigkeit für ν beseitigt wird:

$$P(y) = \frac{Q(y)2^{-\nu-1}2^{-\sum_{j=1}^k \lambda_j f_j(y)}}{\sum_{a \in E} Q(a)2^{-\nu-1}2^{-\sum_{j=1}^k \lambda_j f_j(a)}} = \frac{Q(y)2^{-\nu-1}2^{-\sum_{j=1}^k \lambda_j f_j(y)}}{2^{-\nu-1} \sum_{a \in E} Q(a)2^{-\sum_{j=1}^k \lambda_j f_j(a)}} \implies$$

$$P(y) = \frac{Q(y)2^{-\sum_{j=1}^k \lambda_j f_j(y)}}{\sum_{a \in E} Q(a)2^{-\sum_{j=1}^k \lambda_j f_j(a)}}. \quad (9.4)$$

Anwendung dieses Ansatzes auf jedes $P(y)$ ergibt uns $|E|$ Gleichungen obiger Form. Indem wir dies mit unseren k Bedingungsgleichungen zusammensetzen, haben wir $|E| + k$ Gleichungen und $|E| + k$ Unbekannte, was bedeutet, dass wir das System für jedes $P(a)$ lösen und die λ_j so wählen können, dass sie unsere Bedingungen erfüllen (üblicherweise numerisch gemacht). Als letztes können wir die zweite Ableitung von (9.3) nehmen und beweisen, indem wir (9.4) einsetzen und Positivität zeigen, dass jenes Extremum tatsächlich ein Minimum ist. Behufs Knappheit, allerdings, unterlassen wir diese Ausrechnungen vermittels eines alternativen Beweises:

$$\begin{aligned} D(P||Q) &= \sum_{a \in E} P(a) \log \frac{P(a)}{Q(a)} = \sum_{a \in E} P(a) \log \frac{P(a)P^*(a)}{P^*(a)Q(a)} = \sum_{a \in E} P(a) \left(\log \frac{P(a)}{P^*(a)} + \log \frac{P^*(a)}{Q(a)} \right) = \\ &= \sum_{a \in E} P(a) \log \frac{P(a)}{P^*(a)} + \sum_{a \in E} P(a) \log \frac{P^*(a)}{Q(a)} = D(P||P^*) + \sum_{a \in E} P(a) \log \frac{P^*(a)}{Q(a)} \stackrel{(i)}{\geq} \sum_{a \in E} P(a) \log \frac{P^*(a)}{Q(a)} = \\ &= \sum_{a \in E} P(a) \log P^*(a) - \sum_{a \in E} P(a) \log Q(a) \stackrel{(9.4)}{=} \sum_{a \in E} P(a) \log \left(\frac{Q(a)2^{-\sum_{j=1}^k \lambda_j f_j(a)}}{\sum_{b \in E} Q(b)2^{-\sum_{j=1}^k \lambda_j f_j(b)}} \right) - \sum_{a \in E} P(a) \log Q(a) = \\ &= \sum_{a \in E} P(a) \log 2^{-\sum_{j=1}^k \lambda_j f_j(a)} + \sum_{a \in E} P(a) \log Q(a) - \sum_{a \in E} P(a) \log \left(\sum_{b \in E} Q(b)2^{-\sum_{j=1}^k \lambda_j f_j(b)} \right) - \sum_{a \in E} P(a) \log Q(a) = \\ &= \sum_{a \in E} P(a) \left(-\sum_{j=1}^k \lambda_j f_j(a) \right) - \log \left(\sum_{b \in E} Q(b)2^{-\sum_{j=1}^k \lambda_j f_j(b)} \right) \sum_{a \in E} P(a) \stackrel{(ii)}{=} \\ &= \sum_{a \in E} P^*(a) \left(-\sum_{j=1}^k \lambda_j f_j(a) \right) - \log \left(\sum_{b \in E} Q(b)2^{-\sum_{j=1}^k \lambda_j f_j(b)} \right) \sum_{a \in E} P^*(a) = \\ &= \sum_{a \in E} P^*(a) \log 2^{-\sum_{j=1}^k \lambda_j f_j(a)} - \sum_{a \in E} P^*(a) \log \left(\sum_{b \in E} Q(b)2^{-\sum_{j=1}^k \lambda_j f_j(b)} \right) + \sum_{a \in E} P^*(a) \log Q(a) - \sum_{a \in E} P^*(a) \log Q(a) = \\ &= \sum_{a \in E} P^*(a) \log \left(\frac{Q(a)2^{-\sum_{j=1}^k \lambda_j f_j(a)}}{\sum_{b \in E} Q(b)2^{-\sum_{j=1}^k \lambda_j f_j(b)}} \right) - \sum_{a \in E} P^*(a) \log Q(a) = \\ &= \sum_{a \in E} P^*(a) \log P^*(a) - \sum_{a \in E} P^*(a) \log Q(a) = \sum_{a \in E} P^*(a) \log \frac{P^*(a)}{Q(a)} = D(P^*||Q), \end{aligned}$$

wo P jegliche andere bedingungserfüllende Verteilung ist.

Anmerkungen

- (i) folgt aus der nicht-Negativität der Kullback-Leibler Divergenz.
- (ii) stammt aus der Tatsache, dass sowohl P als auch P^* Wahrscheinlichkeitsmaße sind (also $\sum_{a \in E} P(a) = 1 = \sum_{a \in E} P^*(a)$), welche auch unsere Bedingungen erfüllen.

- Zuletzt sehen wir, dass wir Gleichheit genau dann haben, wenn die Kullback-Leibler Divergenz von P nach P^* Null ist, was genau dann hält, wenn $P = P^*$ nach der positiv-Definiertheit der Kullback-Leibler Divergenz. Deshalb, als zusätzliches Resultat, sehen wir, dass unser Minimierer P^* eindeutig ist.
- Man kann ein analoges Resultat für stetige Zufallsvariablen zeigen. Man müsse lediglich Summen mit Integralen und Massenfunktionen mit Dichten ersetzen. Wir haben jedoch keine eindeutige minimierende Dichte mehr, sondern nur eine eindeutige Äquivalenzklasse von Dichten, wobei unsere Äquivalenzrelation fast sichere Gleichheit ist. i.a.W., die minimierende Dichte ist bis auf eine Nullmenge eindeutig definiert (d. H., eine Menge Lebesgue-Maßes Null [15]). Dies ist weil, im kontinuierlichen Falle, die Kullback-Leibler Divergenz positiv semi-definit ist, blind für Unterschiede von Dichtenfunktionen auf Nullmengen.

Als einfaches Beispiel können wir die Wahrscheinlichkeit betrachten, dass n Rollen eines fairen Würfels einen empirischen Durchschnitt von größer gleich vier ergibt [2]. In jenem Falle sind unser Quellenalphabet $E := \{1, 2, 3, 4, 5, 6\}$, unsere generische Verteilung Q uniform und $\mathcal{A}$ kann als:

$$\mathcal{A} := \left\{ P \in \mathcal{P} \left| \sum_{i=1}^6 iP(i) \geq 4 \right. \right\}.$$

geschrieben werden. Daher haben wir eine Bedingung. lt. (9.4):

$$P^*(y) = \frac{\frac{1}{6}2^{-\lambda y}}{\sum_{a \in E} \frac{1}{6}2^{-\lambda a}} = \frac{2^{-\lambda y}}{\sum_{a \in E} 2^{-\lambda a}}.$$

Indem wir numerisch lösen, erlangen wir $\lambda \approx 0.25$, $P^*(1) \approx 0.10$, $P^*(2) \approx 0.12$, $P^*(3) \approx 0.15$, $P^*(4) \approx 0.17$, $P^*(5) \approx 0.21$, und $P^*(6) \approx 0.25$. Indem wir P^* in $D(P||Q)$ einsetzen, erhalten wir $D(P^*||Q) \approx 0.06$. Folglich lässt uns die Sanov'sche Ungleichung folgern: $P(T(\mathcal{A})) \leq (n+1)^6 2^{-0.06n}$.

Ein weiteres Beispiel ist eine faire Münze [2]. Wir haben Quellenalphabet $E := \{0, 1\}$ und uniforme Verteilung $Q \sim \text{Ber}(\frac{1}{2})$. Falls wir die Wahrscheinlichkeit finden möchten, dass unsere Folge aus mehr als 70% Köpfen besteht, bspw., dann:

$$\mathcal{A} := \left\{ P \in \mathcal{P} \left| \frac{P(1) + P(0)}{2} \geq 0.7 \right. \right\}.$$

Offenbar wird das maximierende $P^*(1) = 0.7$ und $P^*(0) = 0.3$ sein, was $D\left(P^* \left\| \text{Ber}\left(\frac{1}{2}\right)\right.\right) = 0.119$ ergibt, was bedeutet, dass $P(T(\mathcal{A})) \leq (n+1)^2 2^{-0.119n}$.

Anmerkung: In den obigen Beispielen sieht man die Grenzen unserer Ungleichung wenn n nicht groß ist. z. B., unsere erste Ungleichung fällt erst bei $n = 997$ unter eins und unsere zweite bei $n = 116$. Indessen feinere Schranken, asymptotisch (siehe Absatz nach dem Beweis der Sanov'schen Ungleichung), wenig Unterschied machen, können sie für kleinere n als bessere Schranken dienen. Ein Beispiel jener Verfeinerungen kann bei Chernoff'schen Schranken gesehen werden, welche außerhalb des Rahmens dieser Arbeit liegen [16]. Man könnte die Ungleichung auch dadurch feiner machen, indem man die einigermaßen grobe Ungleichung im Lemma 4 verfeinert (jene neue, feinere Ungleichung kann die alte ersetzen, welche im Beweis der Sanov'schen Ungleichung verwendet wurde). Nichtsdestoweniger arbeitet man in der eher überwiegenden Mehrheit von Anwendungen mit großem n . Darüber hinaus, in Situationen, wo die Ausführung eines Experiments/Versuchs Ressourcen-teuer ist, ist einer effizienten Lösung eine feinere Schätzung unerlässlich. Ob es darum geht, die Wahrscheinlichkeit des Vorkommnisses eines widrigen Effekts eines neuen Medikaments, oder die Wahrscheinlichkeit, dass das Material, das eine Brücke ausmacht krümelig wird, zu ermitteln, eine einfache Anwendung der Sanov'schen Ungleichung liefert eine wertvolle feine obere Schranke.

Literatur

- [1] Csiszár, I. and Körner, J. (1981) Information Theory, Coding Theorems for Discrete Memoryless Systems, Akadémiai Kiadó, Budapest.
- [2] Cover, T. M., Thomas, J. A. (2010). Elements of information theory. Wiley-India.
- [3] Lecture 15: Strong, conditional, joint typicality. (n.d.). https://web.stanford.edu/class/ee376a/files/2017-18/lecture_15.pdf
- [4] Csiszar, I. (1975). *I*-Divergence Geometry of Probability Distributions and Minimization Problems. The Annals of Probability, 3(1), 146–158. <http://www.jstor.org/stable/2959270>
- [5] Csiszar, I. (1984). Sanov Property, Generalized I-Projection and a Conditional Limit Theorem. The Annals of Probability, 12(3), 768–793. <http://www.jstor.org/stable/2243326>
- [6] E. Borel, Les probabilités dénombrables et leurs applications arithmétiques Rend. Circ. Mat. Palermo (2) 27 (1909) pp. 247–271.
- [7] F.P. Cantelli, "Sulla probabilità come limite della frequenza", Atti Accad. Naz. Lincei 26:1 (1917) pp.39–45.
- [8] L'Hospital (1696). Analyse des infiniment petits. pp. 145–146.
- [9] Thomasian, A. J. (1960). An Elementary Proof of the AEP of Information Theory. The Annals of Mathematical Statistics, 31(2), 452–456. <http://www.jstor.org/stable/2237961>
- [10] Van Dat, T., Dzung, N. C., Van, V. T. H. (2023). On the notions of stochastic domination and uniform integrability in the Cesàro sense with applications to weak laws of large numbers for random fields. Lithuanian Mathematical Journal, 63(1), 44–57. doi: 10.1007/s10986-023-09588-x
- [11] Algoet, P. H., Cover, T. M. (1988). A Sandwich Proof of the Shannon-McMillan-Breiman Theorem. The Annals of Probability, 16(2), 899–909. <http://www.jstor.org/stable/2243846>
- [12] Topics functional analysis - univie.ac.at. (n.d.-b). <https://www.mat.univie.ac.at/gerald/ftp/book-fa/fa.pdf>
- [13] Lévy-Prokhorov metric. Lévy-Prokhorov metric - Encyclopedia of Mathematics. (n.d.). https://encyclopediaofmath.org/wiki/L%C3%A9vy-Prokhorov_metric
- [14] Kalman, D. (2009). Leveling with Lagrange: An Alternate View of Constrained Optimization. In Mathematics magazine (Vol. 82, pp. 186–196). Washington: Mathematical Association of America. doi: 10.1080/0025570X.2009.11953617
- [15] Lebesgue, H. (1902). Intégrale, Longueur, Aire. <https://doi.org/10.1007/bf02420592>
- [16] Herman Chernoff. A Measure of Asymptotic Efficiency for Tests of a Hypothesis Based on the sum of Observations. Ann. Math. Statist. 23 (4) 493 - 507, December, 1952. <https://doi.org/10.1214/aoms/1177729330>
- [17] Санов, И. Н. (1957) "О вероятности больших отклонений случайных величин". МАТЕМАТИЧЕСКИЙ СБОРНИК' 42(84), No. 1, 11–44.
- [18] Quantization for probability distributions - an introduction. (n.d.-b). <https://www.math.hu-berlin.de/~romisch/papers/quantization.pdf>